

Снижение размерности в задачах декодирования временных рядов и прогнозирования*

Р. В. Исаченко¹, М. Р. Владимирова², В. В. Стрижов³

Аннотация: Решается задача обнаружения зависимостей в прогнозируемой переменной. Вместо построения прогноза одного момента времени предлагается прогнозировать многомерный вектор прогноза. Рассматривается линейная модель метода частных наименьших квадратов. Описан метод нахождения матрицы совместного описания для исходных матриц объектов и ответов. Найденное описание является низкоразмерным, что позволяет построить устойчивую, простую модель. Проводится вычислительный эксперимент на реальных данных объемов потребления электроэнергии и данных сигналов кортикограмм.

Ключевые слова: декодирование временных рядов; метод частных наименьших квадратов; PLS; снижение размерности

1. Введение

В работе рассматривается задача восстановления зависимости между независимой и прогнозируемой переменными. Предлагаемая модель позволяет восстанавливать зависимость в случае многомерной прогнозируемой переменной. В случае задачи прогнозирования пространства объектов и ответов имеют одну и ту же природу. Для построения модели по исходному временному ряду строятся авторегрессионные матрицы объектов и ответов. Объектом является локальная история сигнала, ответом — значение сигнала в следующие моменты времени. Авторегрессионная модель предполагает, что значение сигнала в данный момент времени линейно зависит от предыдущих значений этого же сигнала.

В случае, если пространства объектов и ответов имеют разную природу, ответом является отклик системы на входной сигнал. Авторегрессионная матрица объектов

*Работа выполнена при финансовой поддержке РФФИ (проект 16-07-01155).

¹Московский физико-технический институт, isa-ro@yandex.ru

²Московский физико-технический институт, vladimirova.maria@phystech.edu

³Вычислительный центр им. А. А. Дородницына ФИЦ ИУ РАН, strijov@ccas.ru

содержит локальную историю входного сигнала, а авторегрессионная матрица ответов содержит локальную историю отклика.

Исходное признаковое пространство оказывается многомерным. Избыточная размерность признакового пространства приводит к неустойчивости модели. Для решения этой проблемы используются методы отбора признаков [1].

В работе исследуется метод частных наименьших квадратов (PLS) [2–4]. Метод частных наименьших квадратов снижает размерности матрицы признаков и выделяет линейные комбинации признаков, которые оказывают наибольшее влияние на вектор ответов. Выделение признаков происходит итеративно, в порядке уменьшения их влияния на вектор ответов. Рассматриваются только значимые комбинации признаков, незначительно потеряв в точности прогноза. Методы PLS регрессии подробно описаны в работах [5,6]. Разницу между методом PLS и связанными с ним подходами, различные разновидности регрессии PLS можно найти в [7].

Нелинейное расширение метода PLS регрессии впервые введено в [8]. В литературе были разработаны различные модификации PLS. Предложены нелинейные методы PLS, основанные на различных моделях: сглаживающих сплайнах ?? нейронных сетях [9], базисных радиальных функциях [10], генетическом алгоритме ?. Обзор нелинейных методов PLS можно найти в ??.

Результатом применения отбора признаков является снижение размерности задачи и повышение устойчивости моделей без существенной потери точности прогноза. Методы решения данной задачи сравниваются на двух наборах данных, имеющих избыточную информацию. Первый набор данных — почасовые временные ряды объёмов потребления электроэнергии (долгота: 21,25, широта: 52,30, высота над уровнем моря: 94). Временные ряды соответствуют периоду 1999-2004 годов.

Второй набор данных взят из проекта NeuroTycho [11], в котором проектируется нейрокомпьютерный интерфейс (BCI) для обмена информацией между мозгом и электронным устройством. Система BCI повышает умственные и физические способности пользователя, обеспечивая прямую связь между мозгом и компьютером [12]. BCI восстанавливает поврежденную функциональность пациентов с нарушениями двигательного или когнитивного развития. Цель анализа моторных изображений заключается в распознавании предполагаемых движений по записанной активности мозга. Существуют различные методы измерения кортикальных данных для BCI описанные в [13, 14]. В работе рассматриваются сигналы электрокортикографии (ECoG) [15]. ECoG, как и другие инвазивные методы, обеспечивает более стабильную запись и лучшее разрешение в временных и пространственных областях, чем ее неинвазивные аналоги. Данные ECoG являются высокомерными и измерения коррелируют как во временной, так и в пространственной областях. Задача состоит в предсказании траектории движения руки по временным рядам напряжения кортикальной активности. Сигналы ECoG измеряются через 32 канала, в то время как субъект перемещает руку.

Предлагаемый метод позволил существенно снизить размерность признакового пространства.

2 Постановка задачи

Задана выборка $\mathfrak{D} = (\mathbf{X}, \mathbf{Y})$, где $\mathbf{X} \in \mathbb{R}^{m \times n}$ — матрица объектов, $\mathbf{Y} \in \mathbb{R}^{m \times r}$ — матрица ответов. Способ построения выборки под определенную прикладную задачу описан в разделе "Вычислительный эксперимент".

Предположим, что между объектами $\mathbf{x} \in \mathbb{R}^n$ и ответами $\mathbf{y} \in \mathbb{R}^r$ существует линейная зависимость

$$\underset{1 \times r}{\mathbf{y}} = \underset{1 \times n}{\mathbf{x}} \cdot \underset{n \times r}{\boldsymbol{\Theta}} + \underset{1 \times r}{\boldsymbol{\epsilon}}, \quad (1)$$

где $\boldsymbol{\Theta}$ — матрица параметров модели, а $\boldsymbol{\epsilon}$ — вектор регрессионных остатков.

Необходимо по известной выборке \mathfrak{D} восстановить матрицу параметров модели (1). Оптимальные параметры находятся минимизацией функции ошибки. Введем квадратичную функцию ошибки S на выборке \mathfrak{D} :

$$S(\boldsymbol{\Theta}|\mathfrak{D}) = \left\| \underset{m \times n}{\mathbf{X}} \cdot \underset{n \times r}{\boldsymbol{\Theta}} - \underset{m \times r}{\mathbf{Y}} \right\|_2^2 = \sum_{i=1}^m \left\| \underset{1 \times n}{\mathbf{x}_i} \cdot \underset{n \times r}{\boldsymbol{\Theta}} - \underset{1 \times r}{\mathbf{y}_i} \right\|_2^2 \rightarrow \min_{\boldsymbol{\Theta}}. \quad (2)$$

Линейная зависимость столбцов матрицы \mathbf{X} приводит к неустойчивому решению задачи оптимизации (2). Для устранения линейной зависимости применяются методы отбора признаков.

3 Метод частных наименьших квадратов (PLS)

Для устранения линейной зависимости и снижения размерности пространства применяется метод главных компонент (PCA). Основным недостатком данного метода является то, что он не учитывает взаимосвязь между объектами и ответами. Метод частных наименьших квадратов (PLS) проецирует матрицу объектов \mathbf{X} и матрицу ответов \mathbf{Y} в латентное пространство \mathbb{R}^l меньшей размерности ($l < r < n$). Алгоритм PLS находит в латентном пространстве матрицу $\mathbf{T} \in \mathbb{R}^{m \times l}$, наилучшим образом описывающую исходные матрицы \mathbf{X} и \mathbf{Y} .

Матрица объектов \mathbf{X} и матрица ответов \mathbf{Y} проецируются на латентное пространство следующим образом:

$$\underset{m \times n}{\mathbf{X}} = \underset{m \times l}{\mathbf{T}} \cdot \underset{l \times n}{\mathbf{P}^\top} + \underset{m \times n}{\mathbf{F}} = \sum_{k=1}^l \underset{m \times 1}{\mathbf{t}_k} \cdot \underset{1 \times n}{\mathbf{p}_k^\top} + \underset{m \times n}{\mathbf{F}}, \quad (3)$$

$$\underset{m \times r}{\mathbf{Y}} = \underset{m \times l}{\mathbf{T}} \cdot \underset{l \times r}{\mathbf{Q}^\top} + \underset{m \times r}{\mathbf{E}} = \sum_{k=1}^l \underset{m \times 1}{\mathbf{t}_k} \cdot \underset{1 \times r}{\mathbf{q}_k^\top} + \underset{m \times r}{\mathbf{E}}, \quad (4)$$

где \mathbf{T} — матрица совместного описания объектов и ответов в латентном пространстве, причём столбцы матрицы \mathbf{T} ортогональны; \mathbf{P} , \mathbf{Q} — матрицы перехода из латентного пространства в исходные пространства; \mathbf{E} , \mathbf{F} — матрицы невязок.

80 Псевдокод метода регрессии PLS приведен в алгоритме 1. Алгоритм итеративно на
 81 каждом из l шагов вычисляет по одному столбцу \mathbf{t}_k , \mathbf{p}_k , \mathbf{q}_k матриц \mathbf{T} , \mathbf{P} , \mathbf{Q} соответ-
 82 ственно. После вычисления следующего набора векторов из матриц \mathbf{X} , \mathbf{Y} вычитаются
 83 очередные одноранговые аппроксимации. Первым шагом необходимо произвести нор-
 84 мировку столбцов исходных матриц (вычесть среднее и разделить на стандартное
 85 отклонение).

Algorithm 1 Алгоритм PLSR

Require: $\mathbf{X}, \mathbf{Y}, l$;

Ensure: $\mathbf{T}, \mathbf{P}, \mathbf{Q}$;

```

1: нормировать матрицы  $\mathbf{X}$  и  $\mathbf{Y}$  по столбцам
2: инициализировать  $\mathbf{u}_0$  (первый столбец матрицы  $\mathbf{Y}$ )
3:  $\mathbf{X}_1 = \mathbf{X}; \mathbf{Y}_1 = \mathbf{Y}$ 
4: for  $k = 1, \dots, l$  do
5:   repeat
6:      $\mathbf{w}_k := \mathbf{X}_k^\top \mathbf{u}_{k-1} / (\mathbf{u}_{k-1}^\top \mathbf{u}_{k-1}); \quad \mathbf{w}_k := \frac{\mathbf{w}_k}{\|\mathbf{w}_k\|}$ 
7:      $\mathbf{t}_k := \mathbf{X}_k \mathbf{w}_k$ 
8:      $\mathbf{c}_k := \mathbf{Y}_k^\top \mathbf{t}_k / (\mathbf{t}_k^\top \mathbf{t}_k); \quad \mathbf{c}_k := \frac{\mathbf{c}_k}{\|\mathbf{c}_k\|}$ 
9:      $\mathbf{u}_k := \mathbf{Y}_k \mathbf{c}_k$ 
10:   until  $\mathbf{t}_k$  не стабилизируется
11:    $\mathbf{p}_k := \mathbf{X}_k^\top \mathbf{t}_k / (\mathbf{t}_k^\top \mathbf{t}_k), \quad \mathbf{q}_k := \mathbf{Y}_k^\top \mathbf{t}_k / (\mathbf{t}_k^\top \mathbf{t}_k)$ 
12:    $\mathbf{X}_{k+1} := \mathbf{X}_k - \mathbf{t}_k \mathbf{p}_k^\top$ 
13:    $\mathbf{Y}_{k+1} := \mathbf{Y}_k - \mathbf{t}_k \mathbf{q}_k^\top$ 

```

86 Вектора \mathbf{t}_k и \mathbf{u}_k из внутреннего цикла алгоритма 1 содержат информацию о матри-
 87 це объектов \mathbf{X} и матрице ответов \mathbf{Y} соответственно. Блоки из шагов (6)-(7) и шагов
 88 (8)-(9) — аналоги алгоритма PCA для матриц \mathbf{X} и \mathbf{Y} (ссылка). Последовательное
 89 выполнение блоков позволяет учесть взаимную связь между матрицами \mathbf{X} и \mathbf{Y} .

90 Теоретическое обоснование алгоритма PLS следует из следующих утверждений.

91 **Утверждение 1** *Наилучшее описание матриц \mathbf{X} и \mathbf{Y} с учётом их взаимосвязи до-*
 92 *стигается при максимизации ковариации между векторами \mathbf{t}_k и \mathbf{u}_k .*

93 *Утверждение следует из равенства*

$$\text{cov}(\mathbf{t}_k, \mathbf{u}_k) = \text{corr}(\mathbf{t}_k, \mathbf{u}_k) \cdot \sqrt{\text{var}(\mathbf{t}_k)} \cdot \sqrt{\text{var}(\mathbf{u}_k)}.$$

94 *Максимизация дисперсий векторов \mathbf{t}_k и \mathbf{u}_k отвечает за сохранение информации об*
 95 *исходных матрицах, корреляция между векторами отвечает взаимосвязи между*
 96 *\mathbf{X} и \mathbf{Y} .*

97 Во внутреннем цикле алгоритма вычисляются нормированные вектора весов \mathbf{w}_k и \mathbf{c}_k .
 98 Из данных векторов строятся матрицы весов \mathbf{W} и \mathbf{C} соответственно.

Утверждение 2 Обновление векторов по шагам (6)–(9) алгоритма 1 соответствует максимизации ковариации между векторами \mathbf{t}_k и \mathbf{u}_k .

$$\begin{aligned} \max_{\mathbf{t}_k, \mathbf{u}_k} \text{cov}(\mathbf{t}_k, \mathbf{u}_k)^2 &= \max_{\substack{\|\mathbf{w}_k\|=1 \\ \|\mathbf{c}_k\|=1}} \text{cov}(\mathbf{X}_k \mathbf{w}_k, \mathbf{Y}_k \mathbf{c}_k)^2 = \max_{\substack{\|\mathbf{w}_k\|=1 \\ \|\mathbf{c}_k\|=1}} \text{cov}\left(\mathbf{c}_k^\top \mathbf{Y}_k^\top \mathbf{X}_k \mathbf{w}_k\right)^2 = \\ &= \max_{\|\mathbf{w}_k\|=1} \text{cov}\left\|\mathbf{Y}_k^\top \mathbf{X}_k \mathbf{w}_k\right\|^2 = \max_{\|\mathbf{w}_k\|=1} \mathbf{w}_k^\top \mathbf{X}_k^\top \mathbf{Y}_k \mathbf{Y}_k^\top \mathbf{X}_k \mathbf{w}_k = \\ &= \lambda_{\max}\left(\mathbf{X}_k^\top \mathbf{Y}_k \mathbf{Y}_k^\top \mathbf{X}_k\right), \end{aligned}$$

99 где $\lambda_{\max}(\mathbf{A})$ — максимальное собственное значение матрицы \mathbf{A} .

100 **Утверждение 3** В результате выполнения внутреннего цикла вектора \mathbf{w}_k и \mathbf{c}_k бу-
101 дут собственными векторами матриц $\mathbf{X}_k^\top \mathbf{Y}_k \mathbf{Y}_k^\top \mathbf{X}_k$ и $\mathbf{Y}_k^\top \mathbf{X}_k \mathbf{X}_k^\top \mathbf{Y}_k$, соответствую-
102 щими максимальным собственным значениям.

$$\begin{aligned} \mathbf{w}_k &\propto \mathbf{X}_k^\top \mathbf{u}_k \propto \mathbf{X}_k^\top \mathbf{Y}_k \mathbf{c}_k \propto \mathbf{X}_k^\top \mathbf{Y}_k \mathbf{Y}_k^\top \mathbf{t}_k \propto \mathbf{X}_k^\top \mathbf{Y}_k \mathbf{Y}_k^\top \mathbf{X}_k \mathbf{w}_k, \\ \mathbf{c}_k &\propto \mathbf{Y}_k^\top \mathbf{t}_k \propto \mathbf{Y}_k^\top \mathbf{X}_k \mathbf{w}_k \propto \mathbf{Y}_k^\top \mathbf{X}_k \mathbf{X}_k^\top \mathbf{u}_k \propto \mathbf{Y}_k^\top \mathbf{X}_k \mathbf{X}_k^\top \mathbf{Y}_k \mathbf{c}_k, \end{aligned}$$

103 где символ \propto означает равенство с точностью до мультипликативной константы.

104 Утверждение следует из того факта, что правила обновления векторов \mathbf{w}_k , \mathbf{c}_k сов-
105 падают с итерацией алгоритма поиска максимального собственного значения [16].

После завершения внутреннего цикла на шаге (11) вычисляются вектора \mathbf{p}_k , \mathbf{q}_k проецированием столбцов матриц \mathbf{X}_k и \mathbf{Y}_k на вектор \mathbf{t}_k . Для перехода на следующий шаг необходимо вычесть из матриц \mathbf{X}_k и \mathbf{Y}_k одноранговые аппроксимации $\mathbf{t}_k \mathbf{p}_k^\top$ и $\mathbf{t}_k \mathbf{q}_k^\top$

$$\mathbf{X}_{k+1} = \mathbf{X}_k - \mathbf{t}_k \mathbf{p}_k^\top = \mathbf{X} - \sum_k \mathbf{t}_k \mathbf{p}_k^\top,$$

$$\mathbf{Y}_{k+1} = \mathbf{Y}_k - \mathbf{t}_k \mathbf{q}_k^\top = \mathbf{Y} - \sum_k \mathbf{t}_k \mathbf{q}_k^\top,$$

106 Тогда каждый следующий вектор \mathbf{t}_k оказывается ортогонален всем векторам \mathbf{t}_i , $i =$
107 $1, \dots, k$.

108 На Рис. 1 продемонстрирован результат работы алгоритма PLS для случая, ко-
109 гда размерности пространств объектов, ответов и латентного пространства равны 2
110 ($n = r = l = 2$). Синими и зелёными точками изображены строки матриц \mathbf{X} и \mathbf{Y} .
111 Точки были сгенерированы из нормального распределения с нулевым матожиданием.
112 Красным контуром показаны линии уровня матриц ковариаций распределений. Чер-
113 ным изображены единичные окружности. Красные стрелки соответствуют главным
114 компонентам. Черные стрелки соответствуют векторам матриц \mathbf{W} и \mathbf{C} алгоритма
115 PLS. Вектора \mathbf{t}_k и \mathbf{u}_k равны проекциям матриц \mathbf{X}_k и \mathbf{Y}_k на вектора \mathbf{w}_k и \mathbf{c}_k соответ-
116 ственно и изображены черными плюсами. Учёт взаимной связи между матрицами \mathbf{X}

и \mathbf{Y} отклоняет вектора \mathbf{w}_k и \mathbf{c}_k от направления главных компонент. Вектора \mathbf{w}_k отклоняются незначительно. На первой итерации \mathbf{c}_1 близок к pc_1 , но вектора \mathbf{c}_k , найденные на следующих итерациях могут оказаться сильно коррелированными. Это происходит в следствие того, что из матрицы \mathbf{Y} на каждом шаге вычитается одноранговая аппроксимация, найденная в пространстве матрицы \mathbf{X}_k .

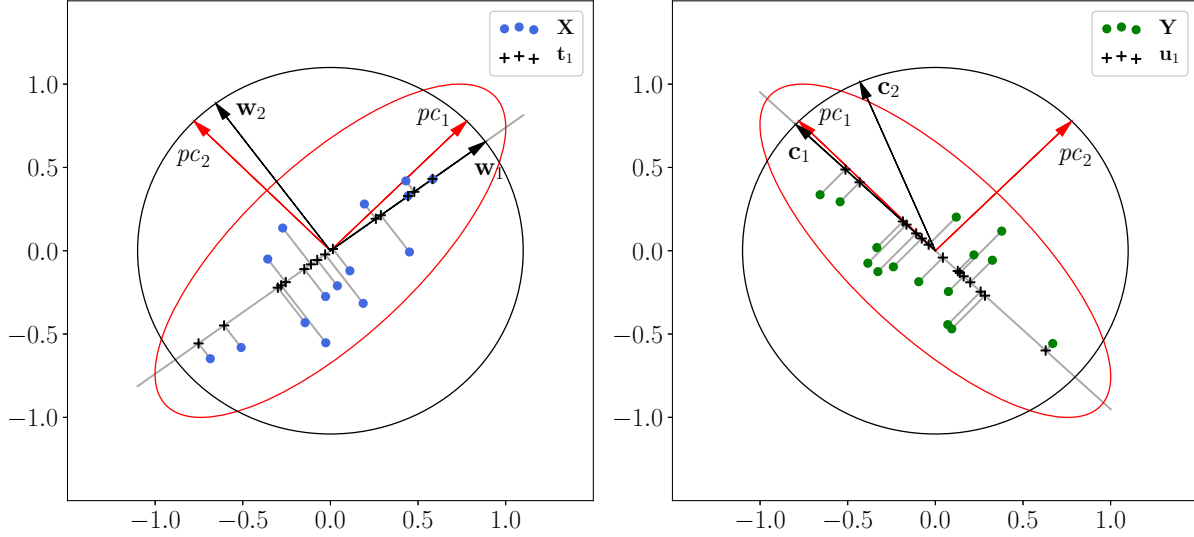


Рис. 1: Иллюстрация алгоритма PLS

Домножим справа формулу (3) на матрицу \mathbf{W} . Строки матрицы невязок \mathbf{E} ортогональны столбцам матрицы \mathbf{W} , поэтому

$$\mathbf{XW} = \mathbf{TP}^T \mathbf{W}.$$

Линейное преобразование между объектами в исходном и латентном пространстве имеет вид

$$\mathbf{T} = \mathbf{XW}^*, \quad (5)$$

где $\mathbf{W}^* = \mathbf{W}(\mathbf{P}^T \mathbf{W})^{-1}$.

Матрица параметров модели 1 находится из уравнений (4), (5)

$$\mathbf{Y} = \mathbf{TQ}^T + \mathbf{E} = \mathbf{XW}^* \mathbf{Q}^T + \mathbf{E} = \mathbf{X}\boldsymbol{\Theta} + \mathbf{E}.$$

Таким образом, параметры модели (1) равны

$$\boldsymbol{\Theta} = \mathbf{W}(\mathbf{P}^T \mathbf{W})^{-1} \mathbf{Q}^T.$$

После нахождения параметров модели на этапе тестирования для нахождения предсказания модели необходимо

- нормировать тестовые данные;

- вычислить предсказание модели с помощью линейного преобразования с матрицей Θ ;
- провести обратную нормировку.

4 Вычислительный эксперимент

Временные ряды энергии состоят из почасовых записей (всего 52512 наблюдений), а погодные измерения проводились раз в день и содержат 2188 наблюдений. Строка матрицы \mathbf{X} — локальная история сигнала за одну неделю $n = 24 \times 7$. Строка матрицы \mathbf{Y} — локальный прогноз потребления электроэнергии в следующие 24 часа $r = 24$. В этом случае матрицы \mathbf{X} и \mathbf{Y} являются авторегрессионными матрицами (можно ссылку).

В случае данных ECoG матрица \mathbf{X} состоит из пространственно-временного спектрального представления временных рядов напряжения, а матрица \mathbf{Y} содержит информацию о положении руки. Процесс генерации матрицы \mathbf{X} из значений напряжения описан в (ссылка на Мотренко). Пространственно-временное описание в каждый момент времени имеет размерность 864, положение руки описывается координатами по трём осям. Один объект состоит из пространственно-временного описания в несколько отсчётов времени. Ответом является положение руки в нескольких следующих моментах времени.

Для оценивания качества аппроксимации вычисляется значение нормированной среднеквадратичной ошибки

$$\text{NMSE} = \frac{\text{MSE}(\mathbf{Y}, \hat{\mathbf{Y}})}{\text{MSE}(\mathbf{Y}, \bar{\mathbf{Y}})}, \quad (6)$$

где $\hat{\mathbf{Y}}$ — прогноз модели, $\bar{\mathbf{Y}}$ — константный прогноз средним значением по столбцам матрицы.

4.1 Данные потребления электроэнергии

Для нахождения оптимальной размерности l латентного пространства все данные потребления электроэнергии были разбиты на обучающую и валидационную части. Обучающая выборка состоит из 700 объектов, валидационная из 370. Зависимость нормированной квадратичной ошибки (6) от размерности l латентного пространства представлена на Рис. 2. Сначала ошибка резко падает при увеличении размерности скрытого пространства, а затем меняется незначительно.

Минимальная ошибка наблюдается при $l = 14$. Построим прогноз потребления электроэнергии при данном l . Результат аппроксимации изображен на Рис. 3. Алгоритм PLS восстановил авторегрессионную зависимость и обнаружил дневную сезонность.




Рис. 2: Прогноз потребления электроэнергии алгоритмом PLS при размерности латентного пространства $l=14$




Рис. 3: Зависимость ошибки от размерности латентного пространства для данных потребления электроэнергии

4.2 Данные электрокортикограммы

На Рис. 4 представлена зависимость нормированной квадратичной ошибки (6) от размерности латентного пространства. Ошибка аппроксимации меняется незначительно при $l > 5$. Таким образом совместное описание пространственно-временного спектрального представления объектов и пространственного положения руки может быть представлено вектором размерности $l \ll n$. Зафиксируем $l = 5$. Пример аппроксимации положения руки изображен на Рис. 5. Сплошными линиями изображены истин-

170 ные координаты руки по всем осям, пунктирными линиями показана аппроксимация
 171 методом PLS.




Рис. 4: Прогноз движения руки данных ECoG алгоритмом PLS при размерности латентного пространства $l = 5$




Рис. 5: Зависимость ошибки от размерности латентного пространства для данных ECoG

5 Заключение

В данной работе предложен новый подход к обнаружению зависимостей в пространстве зависимой переменной задачи прогнозирования временных рядов. Сравнивались результаты прогнозирования временных рядов, полученных с помощью метода частных наименьших квадратов и предложенной модификации. Проведен вычислительный эксперимент на реальных данных потребления электроэнергии в Варшаве. Построенная прогностическая модель показала высокое качество предсказания электрической нагрузки.

Список литературы

- [1] Jundong Li, Kewei Cheng, Suhang Wang, Fred Morstatter, Robert P Trevino, Jiliang Tang, and Huan Liu. Feature selection: A data perspective. *arXiv preprint arXiv:1601.07996*, 2016.
- [2] Jacob A Wegelin et al. A survey of partial least squares (pls) methods, with emphasis on the two-block case. *University of Washington, Department of Statistics, Tech. Rep*, 2000.
- [3] Hervé Abdi. Partial Least Squares (PLS) Regression. *Encyclopedia for research methods for the social sciences*, pages 792–795, 2003.
- [4] Paul Geladi and Bruce R Kowalski. Partial least-squares regression: a tutorial. *Analytica chimica acta*, 185:1–17, 1986.
- [5] Paul Geladi. Notes on the history and nature of partial least squares (PLS) modelling. *Journal of Chemometrics*, 2(January):231–246, 1988.
- [6] Agnar Höskuldsson. PLS regression. *Journal of Chemometrics*, 2(August 1987):581–591, 1988.
- [7] Roman Rosipal and Nicole Kramer. Overview and Recent Advances in Partial Least Squares. *C. Saunders et al. (Eds.): SLSFS 2005, LNCS 3940*, pages 34–51, 2006.
- [8] Svante Wold, Nouna Kettaneh-Wold, and Bert Skagerberg. Nonlinear pls modeling. *Chemometrics and Intelligent Laboratory Systems*, 7(1-2):53–65, 1989.
- [9] S Joe Qin and Thomas J McAvoy. Nonlinear pls modeling using neural networks. *Computers & Chemical Engineering*, 16(4):379–391, 1992.
- [10] Xuefeng F. Yan, Dezhaoh Z. Chen, and Shangxu X. Hu. Chaos-genetic algorithms for optimizing the operating conditions based on RBF-PLS model. *Computers and Chemical Engineering*, 27(10):1393–1404, 2003.
- [11] Project tycho <http://neurotycho.org/food-tracking-task>.

- 205 [12] José del R Millán, Frédéric Renkens, Josep Mouriño, and Wulfram Gerstner. Brain-
206 actuated interaction. *Artificial Intelligence*, 159(1-2):241–259, 2004.
- 207 [13] Luis Fernando Nicolas-Alonso and Jaime Gomez-Gil. Brain computer interfaces, a
208 review. *Sensors*, 12(2):1211–1279, 2012.
- 209 [14] Setare Amiri, Reza Fazel-Rezai, and Vahid Asadpour. A review of hybrid brain-
210 computer interface systems. *Advances in Human-Computer Interaction*, 2013:1, 2013.
- 211 [15] Andrey Eliseyev and Tetiana Aksenova. Penalized multi-way partial least squares for
212 smooth trajectory decoding from electrocorticographic (ecog) recording. *PloS one*,
213 11(5):e0154878, 2016.
- 214 [16] RV Mises and Hilda Pollaczek-Geiringer. Praktische verfahren der
215 gleichungsauflösung. *ZAMM-Journal of Applied Mathematics and*
216 *Mechanics/Zeitschrift für Angewandte Mathematik und Mechanik*, 9(1):58–77,
217 1929.