

# Снижение размерности в задачах декодирования временных рядов и прогнозирования\*

Р. В. Исаченко<sup>1</sup>, М. Р. Владимирова<sup>2</sup>, В. В. Стрижов<sup>3</sup>

**Аннотация:** Решается задача обнаружения зависимостей в прогнозируемой переменной. Вместо построения прогноза одного момента времени предлагается прогнозировать многомерный вектор прогноза. Рассматривается линейная модель метода частных наименьших квадратов. Описан метод нахождения матрицы совместного описания для исходных матриц объектов и ответов. Найденное описание является низкоразмерным, что позволяет построить устойчивую, простую модель. Проводится вычислительный эксперимент на реальных данных объемов потребления электроэнергии и данных сигналов кортикограмм.

**Ключевые слова:** декодирование временных рядов; метод частных наименьших квадратов; PLS; снижение размерности

## 1 Введение

В работе рассматривается задача восстановления зависимости между независимой и прогнозируемой переменными. Предлагаемая модель позволяет восстанавливать зависимость в случае многомерной прогнозируемой переменной. В случае задачи прогнозирования пространства объектов и ответов имеют одну и ту же природу. Для построения модели по исходному временному ряду строятся авторегрессионные матрицы объектов и ответов. Объектом является локальная история сигнала, ответом — значение сигнала в следующие моменты времени. Авторегрессионная модель предполагает, что значение сигнала в данный момент времени линейно зависит от предыдущих значений этого же сигнала.

В задаче декодирования временных рядов пространство объектов имеет значимо большую размерность. В этом случае пространства объектов и ответов имеют разную

---

\*Работа выполнена при финансовой поддержке РФФИ (проект 16-07-01155).

<sup>1</sup>Московский физико-технический институт, isa-ro@yandex.ru

<sup>2</sup>Московский физико-технический институт, vladimirova.maria@phystech.edu

<sup>3</sup>Вычислительный центр им. А. А. Дородницына ФИЦ ИУ РАН, strijov@ccas.ru

природу, ответом является отклик системы на входной сигнал. Авторегрессионная матрица объектов содержит локальную историю входного сигнала, а авторегрессионная матрица ответов содержит локальную историю отклика.

Исходное признаковое пространство является многомерным. Избыточная размерность признакового пространства приводит к неустойчивости модели. Для решения этой проблемы используются методы отбора признаков [1, 2].

В работе исследуется метод частных наименьших квадратов (PLS) [3–5]. Метод частных наименьших квадратов снижает размерности матрицы признаков и выделяет линейные комбинации признаков, которые оказывают наибольшее влияние на вектор ответов. Выделение признаков происходит итеративно, в порядке уменьшения их влияния на вектор ответов. Рассматриваются только значимые комбинации признаков, незначительно потеряв в точности прогноза. Методы PLS регрессии подробно описаны в работах [6–8]. Разницу между методом PLS и связанными с ним подходами, различные разновидности регрессии PLS можно найти в [9].

Современное состояние области и обзор нелинейных модификаций метода PLS описаны [10]. Нелинейное расширение метода PLS регрессии впервые введено в [11]. В литературе были разработаны различные модификации PLS. Предложены нелинейные методы PLS, основанные на различных моделях: сглаживающих сплайнах [12] нейронных сетях [13], базисных радиальных функциях [14], генетическом алгоритме [15].

Результатом отбора признаков является снижение размерности задачи и повышение устойчивости моделей без существенной потери точности прогноза. Методы решения задачи сравниваются на двух наборах данных, имеющих избыточную информацию. Первый набор данных — почасовые временные ряды объёмов потребления электроэнергии. Временные ряды соответствуют периоду 1999-2004 годов.

Второй набор данных взят из проекта NeuroTycho [16], в котором проектируется нейрокомпьютерный интерфейс (BCI) [17, 18] для обмена информацией между мозгом и электронным устройством. Система BCI повышает умственные и физические способности пользователя, обеспечивая прямую связь между мозгом и компьютером [19]. BCI восстанавливает поврежденную функциональность пациентов с нарушениями двигательного или когнитивного развития. Цель анализа моторных изображений заключается в распознавании предполагаемых движений по записанной активности мозга. Существуют различные методы измерения кортикальных данных для BCI описанные в [20, 21]. В работе рассматриваются сигналы электрокортикографии (ECoG) [22]. ECoG, как и другие инвазивные методы, обеспечивает более стабильную запись и лучшее разрешение в временных и пространственных областях, чем ее неинвазивные аналоги. Данные ECoG являются многомерными и измерения коррелируют как во временной, так и в пространственной областях. Задача состоит в предсказании траектории движения руки по временным рядам напряжения кортикальной активности. Сигналы ECoG измеряются через 32 канала, в то время как субъект перемещает руку.

В работах по прогнозированию сложных пространственных временных рядов прогноз выполняется поточно. При необходимости прогнозировать несколько точек одновременно задачу предлагается решать последовательно вычисляя прогноз по точ-

кам. При этом используются предыдущие спрогнозированные значения для получения последующих. Предлагаемый метод позволяет получать временной ряд прогнозируемых значений одновременно с учётом скрытых зависимостей не только в пространстве объектов, но и в пространстве ответов с согласованием этих двух зависимостей. Предлагаемый метод позволил существенно снизить размерность признакового пространства.

## 2 Постановка задачи

Задана выборка  $\mathfrak{D} = (\mathbf{X}, \mathbf{Y})$ , где  $\mathbf{X} \in \mathbb{R}^{m \times n}$  — матрица объектов,  $\mathbf{Y} \in \mathbb{R}^{m \times r}$  — матрица ответов. Способ построения выборки под определенную прикладную задачу описан в разделе *Вычислительный эксперимент*.

Предполагается, что между объектами  $\mathbf{x} \in \mathbb{R}^n$  и ответами  $\mathbf{y} \in \mathbb{R}^r$  существует линейная зависимость

$$\underset{1 \times r}{\mathbf{y}} = \underset{1 \times n}{\mathbf{x}} \cdot \underset{n \times r}{\boldsymbol{\Theta}} + \underset{1 \times r}{\boldsymbol{\varepsilon}}, \quad (1)$$

где  $\boldsymbol{\Theta}$  — матрица параметров модели, а  $\boldsymbol{\varepsilon}$  — вектор регрессионных остатков.

Необходимо по известной выборке  $\mathfrak{D}$  восстановить матрицу параметров модели (1). Оптимальные параметры находятся минимизацией функции ошибки. Введем квадратичную функцию ошибки  $S$  на выборке  $\mathfrak{D}$ :

$$S(\boldsymbol{\Theta}|\mathfrak{D}) = \left\| \underset{m \times n}{\mathbf{X}} \cdot \underset{n \times r}{\boldsymbol{\Theta}} - \underset{m \times r}{\mathbf{Y}} \right\|_2^2 = \sum_{i=1}^m \left\| \underset{1 \times n}{\mathbf{x}_i} \cdot \underset{n \times r}{\boldsymbol{\Theta}} - \underset{1 \times r}{\mathbf{y}_i} \right\|_2^2 \rightarrow \min_{\boldsymbol{\Theta}}. \quad (2)$$

Линейная зависимость столбцов матрицы  $\mathbf{X}$  приводит к неустойчивому решению задачи оптимизации (2). Для устранения линейной зависимости применяются методы отбора признаков.

## 3 Метод частных наименьших квадратов

Для устранения линейной зависимости и снижения размерности пространства применяется метод главных компонент PCA. Основным недостатком данного метода является то, что он не учитывает взаимосвязь между объектами и ответами. Метод частных наименьших квадратов PLS проецирует матрицу объектов  $\mathbf{X}$  и матрицу ответов  $\mathbf{Y}$  в латентное пространство  $\mathbb{R}^l$  меньшей размерности ( $l < r < n$ ). Алгоритм PLS находит в латентном пространстве матрицу  $\mathbf{T} \in \mathbb{R}^{m \times l}$ , наилучшим образом описывающую исходные матрицы  $\mathbf{X}$  и  $\mathbf{Y}$ .

Матрица объектов  $\mathbf{X}$  и матрица ответов  $\mathbf{Y}$  проецируются в латентное пространство

следующим образом:

$$\mathbf{X} = \mathbf{T} \cdot \mathbf{P}^\top + \mathbf{F} = \sum_{k=1}^l \mathbf{t}_k \cdot \mathbf{p}_k^\top + \mathbf{F}, \quad (3)$$

$$\mathbf{Y} = \mathbf{T} \cdot \mathbf{Q}^\top + \mathbf{E} = \sum_{k=1}^l \mathbf{t}_k \cdot \mathbf{q}_k^\top + \mathbf{E}, \quad (4)$$

где  $\mathbf{T}$  — матрица совместного описания объектов и ответов в латентном пространстве, причём столбцы матрицы  $\mathbf{T}$  ортогональны;  $\mathbf{P}$ ,  $\mathbf{Q}$  — матрицы перехода из латентного пространства в исходные пространства;  $\mathbf{E}$ ,  $\mathbf{F}$  — матрицы невязок.

Псевдокод метода регрессии PLS приведен в алгоритме 1. Алгоритм итеративно на каждом из  $l$  шагов вычисляет по одному столбцу  $\mathbf{t}_k$ ,  $\mathbf{p}_k$ ,  $\mathbf{q}_k$  матриц  $\mathbf{T}$ ,  $\mathbf{P}$ ,  $\mathbf{Q}$  соответственно. После вычисления следующего набора векторов из матриц  $\mathbf{X}$ ,  $\mathbf{Y}$  вычитаются очередные одноранговые аппроксимации. Первым шагом необходимо произвести нормировку столбцов исходных матриц (вычесть среднее и разделить на стандартное отклонение). На этапе тестирования необходимо провести нормировку тестовых данных, вычислить предсказание модели 1, а затем провести обратную нормировку.

---

#### Algorithm 1 Алгоритм PLSR

---

**Require:**  $\mathbf{X}, \mathbf{Y}, l$ ;

**Ensure:**  $\mathbf{T}, \mathbf{P}, \mathbf{Q}$ ;

- 1: нормировать матрицы  $\mathbf{X}$  и  $\mathbf{Y}$  по столбцам
  - 2: инициализировать  $\mathbf{u}_0$  (первый столбец матрицы  $\mathbf{Y}$ )
  - 3:  $\mathbf{X}_1 = \mathbf{X}$ ;  $\mathbf{Y}_1 = \mathbf{Y}$
  - 4: **for**  $k = 1, \dots, l$  **do**
  - 5:   **repeat**
  - 6:      $\mathbf{w}_k := \mathbf{X}_k^\top \mathbf{u}_{k-1} / (\mathbf{u}_{k-1}^\top \mathbf{u}_{k-1})$ ;    $\mathbf{w}_k := \frac{\mathbf{w}_k}{\|\mathbf{w}_k\|}$
  - 7:      $\mathbf{t}_k := \mathbf{X}_k \mathbf{w}_k$
  - 8:      $\mathbf{c}_k := \mathbf{Y}_k^\top \mathbf{t}_k / (\mathbf{t}_k^\top \mathbf{t}_k)$ ;    $\mathbf{c}_k := \frac{\mathbf{c}_k}{\|\mathbf{c}_k\|}$
  - 9:      $\mathbf{u}_k := \mathbf{Y}_k \mathbf{c}_k$
  - 10:   **until**  $\mathbf{t}_k$  не стабилизируется
  - 11:    $\mathbf{p}_k := \mathbf{X}_k^\top \mathbf{t}_k / (\mathbf{t}_k^\top \mathbf{t}_k)$ ,  $\mathbf{q}_k := \mathbf{Y}_k^\top \mathbf{t}_k / (\mathbf{t}_k^\top \mathbf{t}_k)$
  - 12:    $\mathbf{X}_{k+1} := \mathbf{X}_k - \mathbf{t}_k \mathbf{p}_k^\top$
  - 13:    $\mathbf{Y}_{k+1} := \mathbf{Y}_k - \mathbf{t}_k \mathbf{q}_k^\top$
- 

Вектора  $\mathbf{t}_k$  и  $\mathbf{u}_k$  из внутреннего цикла алгоритма 1 содержат информацию о матрице объектов  $\mathbf{X}$  и матрице ответов  $\mathbf{Y}$  соответственно. Блоки из шагов (6)-(7) и шагов (8)-(9) — аналоги алгоритма PCA для матриц  $\mathbf{X}$  и  $\mathbf{Y}$  [5]. Последовательное выполнение блоков позволяет учесть взаимную связь между матрицами  $\mathbf{X}$  и  $\mathbf{Y}$ .

Теоретическое обоснование алгоритма PLS следует из следующих утверждений.

98 **Утверждение 1.** *Наилучшее описание матриц  $\mathbf{X}$  и  $\mathbf{Y}$  с учётом их взаимосвязи*  
 99 *достигается при максимизации ковариации между векторами  $\mathbf{t}_k$  и  $\mathbf{u}_k$ .*

100 Утверждение следует из равенства

$$\text{cov}(\mathbf{t}_k, \mathbf{u}_k) = \text{corr}(\mathbf{t}_k, \mathbf{u}_k) \cdot \sqrt{\text{var}(\mathbf{t}_k)} \cdot \sqrt{\text{var}(\mathbf{u}_k)}.$$

101 Максимизация дисперсий векторов  $\mathbf{t}_k$  и  $\mathbf{u}_k$  отвечает за сохранение информации об  
 102 исходных матрицах, корреляция между векторами отвечает взаимосвязи между  $\mathbf{X}$   
 103 и  $\mathbf{Y}$ . ■

104 Во внутреннем цикле алгоритма вычисляются нормированные вектора весов  $\mathbf{w}_k$  и  
 105  $\mathbf{c}_k$ . Из данных векторов строятся матрицы весов  $\mathbf{W}$  и  $\mathbf{C}$  соответственно.

106 **Утверждение 2.** *В результате выполнения внутреннего цикла вектора  $\mathbf{w}_k$  и  $\mathbf{c}_k$*   
 107 *будут собственными векторами матриц  $\mathbf{X}_k^\top \mathbf{Y}_k \mathbf{Y}_k^\top \mathbf{X}_k$  и  $\mathbf{Y}_k^\top \mathbf{X}_k \mathbf{X}_k^\top \mathbf{Y}_k$ , соответству-*  
 108 *ющими максимальным собственным значениям.*

$$\begin{aligned} \mathbf{w}_k &\propto \mathbf{X}_k^\top \mathbf{u}_{k-1} \propto \mathbf{X}_k^\top \mathbf{Y}_k \mathbf{c}_{k-1} \propto \mathbf{X}_k^\top \mathbf{Y}_k \mathbf{Y}_k^\top \mathbf{t}_{k-1} \propto \mathbf{X}_k^\top \mathbf{Y}_k \mathbf{Y}_k^\top \mathbf{X}_k \mathbf{w}_{k-1}, \\ \mathbf{c}_k &\propto \mathbf{Y}_k^\top \mathbf{t}_k \propto \mathbf{Y}_k^\top \mathbf{X}_k \mathbf{w}_k \propto \mathbf{Y}_k^\top \mathbf{X}_k \mathbf{X}_k^\top \mathbf{u}_{k-1} \propto \mathbf{Y}_k^\top \mathbf{X}_k \mathbf{X}_k^\top \mathbf{Y}_k \mathbf{c}_{k-1}, \end{aligned}$$

109 где символ  $\propto$  означает равенство с точностью до мультипликативной константы.  
 110

111 Утверждение следует из того факта, что правила обновления векторов  $\mathbf{w}_k$ ,  $\mathbf{c}_k$  сов-  
 112 падают с итерацией алгоритма поиска максимального собственного значения. Данный  
 113 алгоритм основан на следующем факте.

114 Если матрица  $\mathbf{A}$  диагонализуема,  $\mathbf{x}$  — некоторый вектор, то

$$\lim_{k \rightarrow \infty} \mathbf{A}^k \mathbf{x} = \lambda_{\max}(\mathbf{A}) \cdot \mathbf{v}_{\max},$$

115 где  $\lambda_{\max}(\mathbf{A})$  — максимальное собственное значение матрицы  $\mathbf{A}$ ,  $\mathbf{v}_{\max}$  — собственный  
 116 вектор матрицы  $\mathbf{A}$ , соответствующий  $\lambda_{\max}(\mathbf{A})$ . ■

117 **Утверждение 3.** *Обновление векторов по шагам (6)–(9) алгоритма 1 соответству-*  
 118 *ет максимизации ковариации между векторами  $\mathbf{t}_k$  и  $\mathbf{u}_k$ .*

Максимальная ковариация между векторами  $\mathbf{t}_k$  и  $\mathbf{u}_k$  равна максимальному соб-  
 ственному значению матрицы  $\mathbf{X}_k^\top \mathbf{Y}_k \mathbf{Y}_k^\top \mathbf{X}_k$ :

$$\begin{aligned} \max_{\mathbf{t}_k, \mathbf{u}_k} \text{cov}(\mathbf{t}_k, \mathbf{u}_k)^2 &= \max_{\substack{\|\mathbf{w}_k\|=1 \\ \|\mathbf{c}_k\|=1}} \text{cov}(\mathbf{X}_k \mathbf{w}_k, \mathbf{Y}_k \mathbf{c}_k)^2 = \max_{\substack{\|\mathbf{w}_k\|=1 \\ \|\mathbf{c}_k\|=1}} \text{cov}\left(\mathbf{c}_k^\top \mathbf{Y}_k^\top \mathbf{X}_k \mathbf{w}_k\right)^2 = \\ &= \max_{\|\mathbf{w}_k\|=1} \text{cov}\left\|\mathbf{Y}_k^\top \mathbf{X}_k \mathbf{w}_k\right\|^2 = \max_{\|\mathbf{w}_k\|=1} \mathbf{w}_k^\top \mathbf{X}_k^\top \mathbf{Y}_k \mathbf{Y}_k^\top \mathbf{X}_k \mathbf{w}_k = \\ &= \lambda_{\max}\left(\mathbf{X}_k^\top \mathbf{Y}_k \mathbf{Y}_k^\top \mathbf{X}_k\right), \end{aligned}$$

119 где  $\lambda_{\max}(\mathbf{A})$  — максимальное собственное значение матрицы  $\mathbf{A}$ . Применяя утвержде-  
 120 ние 2, получаем требуемое. ■

После завершения внутреннего цикла на шаге (11) вычисляются вектора  $\mathbf{p}_k$ ,  $\mathbf{q}_k$  проецированием столбцов матриц  $\mathbf{X}_k$  и  $\mathbf{Y}_k$  на вектор  $\mathbf{t}_k$ . Для перехода на следующий шаг необходимо вычесть из матриц  $\mathbf{X}_k$  и  $\mathbf{Y}_k$  одноранговые аппроксимации  $\mathbf{t}_k \mathbf{p}_k^\top$  и  $\mathbf{t}_k \mathbf{q}_k^\top$

$$\mathbf{X}_{k+1} = \mathbf{X}_k - \mathbf{t}_k \mathbf{p}_k^\top = \mathbf{X} - \sum_k \mathbf{t}_k \mathbf{p}_k^\top,$$

$$\mathbf{Y}_{k+1} = \mathbf{Y}_k - \mathbf{t}_k \mathbf{q}_k^\top = \mathbf{Y} - \sum_k \mathbf{t}_k \mathbf{q}_k^\top.$$

121 Тогда каждый следующий вектор  $\mathbf{t}_k$  оказывается ортогонален всем векторам  $\mathbf{t}_i$ ,  $i =$   
 122  $1, \dots, k$ .

123 На Рис. 1 продемонстрирован результат работы алгоритма PLS для случая, ко-  
 124 гда размерности пространств объектов, ответов и латентного пространства равны 2  
 125 ( $n = r = l = 2$ ). Синими и зелёными точками изображены строки матриц  $\mathbf{X}$  и  $\mathbf{Y}$ .  
 126 Точки были сгенерированы из нормального распределения с нулевым матожиданием.  
 127 Красным контуром показаны линии уровня матриц ковариаций распределений. Чер-  
 128 ным изображены единичные окружности. Красные стрелки соответствуют главным  
 129 компонентам. Черные стрелки соответствуют векторам матриц  $\mathbf{W}$  и  $\mathbf{C}$  алгоритма  
 130 PLS. Вектора  $\mathbf{t}_k$  и  $\mathbf{u}_k$  равны проекциям матриц  $\mathbf{X}_k$  и  $\mathbf{Y}_k$  на вектора  $\mathbf{w}_k$  и  $\mathbf{c}_k$  соответ-  
 131 ственно и изображены черными плюсами. Учёт взаимной связи между матрицами  $\mathbf{X}$   
 132 и  $\mathbf{Y}$  отклоняет вектора  $\mathbf{w}_k$  и  $\mathbf{c}_k$  от направления главных компонент. Вектора  $\mathbf{w}_k$  откло-  
 133 няются незначительно. На первой итерации  $\mathbf{c}_1$  близок к  $pc_1$ , но вектора  $\mathbf{c}_k$ , найденные  
 134 на следующих итерациях могут оказаться сильно коррелированными. Это происхо-  
 135 дит в следствие того, что из матрицы  $\mathbf{Y}$  на каждом шаге вычитается одноранговая  
 136 аппроксимация, найденная в пространстве матрицы  $\mathbf{X}_k$ .

137 Для получения прогнозов модели и нахождения параметров модели домножим  
 138 справа формулу (3) на матрицу  $\mathbf{W}$ . Строки матрицы невязок  $\mathbf{E}$  ортогональны столб-  
 139 цам матрицы  $\mathbf{W}$ , поэтому

$$\mathbf{XW} = \mathbf{TW}^\top \mathbf{W}.$$

140 Линейное преобразование между объектами в исходном и латентном пространстве  
 141 имеет вид

$$\mathbf{T} = \mathbf{XW}^*, \quad (5)$$

142 где  $\mathbf{W}^* = \mathbf{W}(\mathbf{P}^\top \mathbf{W})^{-1}$ .

Матрица параметров модели 1 находится из уравнений (4), (5)

$$\mathbf{Y} = \mathbf{TQ}^\top + \mathbf{E} = \mathbf{XW}^* \mathbf{Q}^\top + \mathbf{E} = \mathbf{X}\boldsymbol{\Theta} + \mathbf{E}.$$

143 Таким образом, параметры модели (1) равны

$$\boldsymbol{\Theta} = \mathbf{W}(\mathbf{P}^\top \mathbf{W})^{-1} \mathbf{Q}^\top. \quad (6)$$

144 После нахождения параметров модели на этапе тестирования для нахождения пред-  
 145 сказания модели необходимо




Рис. 1: Иллюстрация алгоритма PLS

- нормировать тестовые данные;
- вычислить предсказание модели с помощью линейного преобразования с матрицей  $\Theta$  из (6);
- провести обратную нормировку.

## 4 Вычислительный эксперимент

Временные ряды энергии состоят из почасовых записей (всего 52512 наблюдений), а погодные измерения проводились раз в день и содержат 2188 наблюдений. Строка матрицы  $X$  — локальная история сигнала за одну неделю  $n = 24 \times 7$ . Строка матрицы  $Y$  — локальный прогноз потребления электроэнергии в следующие 24 часа  $r = 24$ . В этом случае матрицы  $X$  и  $Y$  являются авторегрессионными матрицами (можно ссылку).

В случае данных ECoG матрица  $X$  состоит из пространственно-временного спектрального представления временных рядов напряжения, а матрица  $Y$  содержит информацию о положении руки. Процесс генерации матрицы  $X$  из значений напряжения описан в [23]. Признакомое описание в каждый момент времени имеет размерность 864, положение руки описывается координатами по трём осям. Пример данных напряжения с разных каналов и соответствующих пространственных координат руки представлен на Рис. 2. Для прогнозирования движения руки используется авторегрессионный подход. Один объект состоит из признакового описания в несколько отсчётов времени. Ответом является положение руки в нескольких следующих моментах




Рис. 2: Пример данных ECoG. Слева изображены данные напряжения снятые с нескольких каналов, справа — координаты руки по трём осям.

времени. Требуется предсказать положение руки в несколько следующих моментов времени.

Введём среднеквадратичную ошибку для некоторых матриц  $\mathbf{A} = [a_{ij}]$  и  $\mathbf{B} = [b_{ij}]$

$$\text{MSE}(\mathbf{A}, \mathbf{B}) = \sum_{i,j} (a_{ij} - b_{ij})^2.$$

Для оценивания качества аппроксимации вычисляется значение нормированной среднеквадратичной ошибки

$$\text{NMSE}(\mathbf{Y}, \hat{\mathbf{Y}}) = \frac{\text{MSE}(\mathbf{Y}, \hat{\mathbf{Y}})}{\text{MSE}(\mathbf{Y}, \bar{\mathbf{Y}})}, \quad (7)$$

где  $\hat{\mathbf{Y}}$  — прогноз модели,  $\bar{\mathbf{Y}}$  — константный прогноз средним значением по столбцам матрицы.

#### 4.1 Данные потребления электроэнергии

Для нахождения оптимальной размерности  $l$  латентного пространства все данные потребления электроэнергии были разбиты на обучающую и валидационную части. Обучающая выборка состоит из 700 объектов, валидационная из 370. Зависимость нормированной квадратичной ошибки (7) от размерности  $l$  латентного пространства представлена на Рис. 3. Сначала ошибка резко падает при увеличении размерности скрытого пространства, а затем меняется незначительно.

Минимальная ошибка наблюдается при  $l = 14$ . Построим прогноз потребления электроэнергии при данном  $l$ . Результат аппроксимации изображен на Рис. 4. Алгоритм PLS восстановил авторегрессионную зависимость и обнаружил дневную сезонность.






Рис. 3: Прогноз потребления электроэнергии алгоритмом PLS при размерности латентного пространства  $l=14$




Рис. 4: Зависимость ошибки от размерности латентного пространства для данных потребления электроэнергии

## 4.2 Данные электрокортикограммы

На Рис. 5 представлена зависимость нормированной квадратичной ошибки (7) от размерности латентного пространства. Ошибка аппроксимации меняется незначительно при  $l > 5$ . Таким образом совместное описание пространственно-временного спектрального представления объектов и пространственного положения руки может быть представлено вектором размерности  $l \ll n$ . Зафиксируем  $l = 5$ . Пример аппроксимации положения руки изображен на Рис. 6. Сплошными линиями изображены истин-

191 ные координаты руки по всем осям, пунктирными линиями показана аппроксимация  
 192 методом PLS.




Рис. 5: Зависимость ошибки от размерности латентного пространства для данных ECoG




Рис. 6: Прогноз движения руки данных ECoG алгоритмом PLS при размерности латентного пространства  $l = 5$

## 5 Заключение

В данной работе предложен новый подход к обнаружению зависимостей в пространстве зависимой переменной задачи прогнозирования временных рядов. Сравнивались результаты прогнозирования временных рядов, полученных с помощью метода частных наименьших квадратов и предложенной модификации. Проведен вычислительный эксперимент на реальных данных потребления электроэнергии в Варшаве. Построенная прогностическая модель показала высокое качество предсказания электрической нагрузки.

## Список литературы

- [1] AM Katrutsa and VV Strijov. Stress test procedure for feature selection algorithms. *Chemometrics and Intelligent Laboratory Systems*, 142:172–183, 2015.
- [2] Jundong Li, Kewei Cheng, Suhang Wang, Fred Morstatter, Robert P Trevino, Jiliang Tang, and Huan Liu. Feature selection: A data perspective. *arXiv preprint arXiv:1601.07996*, 2016.
- [3] Jacob A Wegelin et al. A survey of partial least squares (pls) methods, with emphasis on the two-block case. *University of Washington, Department of Statistics, Tech. Rep*, 2000.
- [4] Hervé Abdi. Partial Least Squares (PLS) Regression. *Encyclopedia for research methods for the social sciences*, pages 792–795, 2003.
- [5] Paul Geladi and Bruce R Kowalski. Partial least-squares regression: a tutorial. *Analytica chimica acta*, 185:1–17, 1986.
- [6] Paul Geladi. Notes on the history and nature of partial least squares (PLS) modelling. *Journal of Chemometrics*, 2(January):231–246, 1988.
- [7] Agnar Höskuldsson. PLS regression. *Journal of Chemometrics*, 2(August 1987):581–591, 1988.
- [8] Sijmen De Jong. Simpls: an alternative approach to partial least squares regression. *Chemometrics and intelligent laboratory systems*, 18(3):251–263, 1993.
- [9] Roman Rosipal and Nicole Kramer. Overview and Recent Advances in Partial Least Squares. *C. Saunders et al. (Eds.): SLSFS 2005, LNCS 3940*, pages 34–51, 2006.
- [10] Roman Rosipal. Nonlinear partial least squares: An overview. *Chemoinformatics and Advanced Machine Learning Perspectives: Complex Computational Methods and Collaborative Techniques*, pages 169–189, 2011.

- [11] Svante Wold, Nouna Kettaneh-Wold, and Bert Skagerberg. Nonlinear pls modeling. *Chemometrics and Intelligent Laboratory Systems*, 7(1-2):53–65, 1989.
- [12] Ildiko E. Frank. A nonlinear PLS model. *Chemometrics and Intelligent Laboratory Systems*, 8(2):109–119, 1990.
- [13] S Joe Qin and Thomas J McAvoy. Nonlinear pls modeling using neural networks. *Computers & Chemical Engineering*, 16(4):379–391, 1992.
- [14] Xuefeng F. Yan, Dezhao Z. Chen, and Shangxu X. Hu. Chaos-genetic algorithms for optimizing the operating conditions based on RBF-PLS model. *Computers and Chemical Engineering*, 27(10):1393–1404, 2003.
- [15] Hugo Hiden, Ben McKay, Mark Willis, and Gary Montague. Non-linear partial least squares using genetic. In *Genetic Programming 1998: Proceedings of the Third*, pages 128–133. Morgan Kaufmann, 1998.
- [16] Project tycho <http://neurotycho.org/food-tracking-task>.
- [17] José del R Millán, Rüdiger Rupp, Gernot Mueller-Putz, Roderick Murray-Smith, Claudio Giugliemma, Michael Tangermann, Carmen Vidaurre, Febo Cincotti, Andrea Kubler, Robert Leeb, et al. Combining brain–computer interfaces and assistive technologies: State-of-the-art and challenges. *Frontiers in Neuroscience*, 4:161, 2010.
- [18] SG Mason, A Bashashati, M Fatourehchi, KF Navarro, and GE Birch. A comprehensive survey of brain interface technology designs. *Annals of biomedical engineering*, 35(2):137–169, 2007.
- [19] José del R Millán, Frédéric Renkens, Josep Mouriño, and Wulfram Gerstner. Brain-actuated interaction. *Artificial Intelligence*, 159(1-2):241–259, 2004.
- [20] Luis Fernando Nicolas-Alonso and Jaime Gomez-Gil. Brain computer interfaces, a review. *Sensors*, 12(2):1211–1279, 2012.
- [21] Setare Amiri, Reza Fazel-Rezai, and Vahid Asadpour. A review of hybrid brain-computer interface systems. *Advances in Human-Computer Interaction*, 2013:1, 2013.
- [22] Andrey Eliseyev and Tetiana Aksenova. Penalized multi-way partial least squares for smooth trajectory decoding from electrocorticographic (ecog) recording. *PloS one*, 11(5):e0154878, 2016.
- [23] Motrenko A. Gasanov I. Creation of approximating scalogram description in a problem of movement prediction. *Journal of Machine Learning and Data Analysis*, 3(2):160–169, 2017.